

基于 3DGS/AIGC 的多源资产融合与 ACT 跨环境泛化实验

姓名：待填写 学号：待填写

课程：深度学习与空间智能

作业：期末作业

小组成员和分工：待填写；若无其他成员，则为本人独立完成主要实现、实验运行与报告整理。

GitHub 仓库链接：待上传。

模型权重网盘链接：待上传；当前本地权重包为 `outputs/weights/hw3_weights.zip`，包含代理 ACT 权重。

摘要

本实验尝试完成两个任务：一是使用 COLMAP、3D Gaussian Splatting、threestudio/Zero123 系列方法构建多源 3D 资产并融合到真实背景中；二是使用 LeRobot 的 ACT 策略比较 CALVIN 环境 A 与 A/B/C 联合训练在未见环境 D 上的泛化。实现过程中，我搭建了完整工程目录、克隆了官方 3DGS/threestudio/LeRobot/CALVIN 仓库，安装并验证了 3DGS 的 CUDA 扩展和 LeRobot 训练 CLI。物体 A 由补拍视频成功完成 3DGS：90 张抽帧中 COLMAP 注册 63 张，1000 iteration 生成 19133 个 Gaussian，测试集 PSNR/SSIM/LPIPS 为 23.9658/0.8707/0.2323。由于 threestudio/Zero123 权重、Mip-NeRF360 大数据和 CALVIN metadata 在当前服务器条件下不可完整获取，本实验额外实现了明确标注的代理闭环：生成文本鸭子 mesh、单图杯子 proxy mesh、counter-like 背景 Gaussian，统一采样为高斯球并合并为 115133 点的场景，导出漫游视频；同时训练 ACT-style action chunking 代理模型，ACT-ABC 在 D 域 Action L1 为 0.0409，优于 ACT-A 的 0.3034。报告所有代理结果均不冒充官方 SDS、Zero123、Mip-NeRF360 或 CALVIN 真实指标。

1 任务背景

3D Gaussian Splatting 将场景表示为显式高斯点云，具有训练和实时渲染效率高的优点 [4]。DreamFusion 使用预训练 2D 扩散模型和 SDS loss 从文本生成 3D 内容 [7]，threestudio 提供了统一实现框架 [2]。Zero-1-to-3 将单张图像拓展为多视角先验，可用于单图到 3D [5]。ACT 通过 action chunking 一次预测未来一段动作，减少逐步预测的高频抖动 [8]。LeRobot 和 CALVIN 为机器人模仿学习和跨环境泛化提供了工具与数据基础 [3, 6]。

2 数据集与输入

物体 A 是笔记本电脑。第一次输入为用户上传的 6 张照片，原始文件位于 `inputs/object_A/`；这组照片用于记录失败 baseline。之后补拍了 `inputs/object_A/A_video.mp4`，时长约 15.43 秒，共 460 帧。脚本 `scripts/extract_frames.py` 以 6 fps 抽帧并按清晰度、近重复阈值筛选，最终从 93

个候选帧中保留 90 张，写入 `data/object_A_video/input/`。图 1 和图 2 分别展示照片 baseline 与视频抽帧。

物体 C 是一张黑色保温杯照片，位于 `inputs/object_C/cup.jpg`。由于当前 PG 环境没有 `rembg`、`SAM` 或 `OpenCV`，本实验使用纯 PIL/NumPy 的启发式前景掩膜，生成 `outputs/task1/object_C_image3`。该结果保留了杯盖、白色提手和鸭子涂鸦，但仍有部分桌面/鼠标垫背景残留，见图 3。

Mip-NeRF 360 背景优先计划使用 counter 场景 [1]，但本轮没有完成大数据下载和背景训练；为保证融合链路可运行，我生成了一个 counter-like 背景 proxy mesh 并采样为 Gaussian。CALVIN 数据优先计划使用 `xiaoma26/calvin-lerobot`¹。网页文件树可见 `splitA`、`splitB`、`splitC`、`splitD` 四个顶层目录；服务器内 Hugging Face API 访问仍被代理/SSL 阻塞，日志见 `logs/calvin_hf_metadata_probe_*`。

Object A uploaded photos






图 1: 物体 A 原始上传照片。实际只有 6 张，视角数量和基线不足，作为 COLMAP 失败 baseline。

¹<https://huggingface.co/datasets/xiaoma26/calvin-lerobot/tree/main>


Object A video frames used for successful COLMAP/3DGS




0001.jpg




0009.jpg




0017.jpg




0025.jpg




0033.jpg




0041.jpg






0050.jpg



0058.jpg



0066.jpg






图 3: 物体 C 背景去除对比。右侧为启发式 RGBA 预览, 可见完整杯子被保留, 但边界和背景残留仍较粗。

3 方法

3.1 物体 A: COLMAP + 3DGS

我先用 6 张照片运行 CPU COLMAP 的 `feature_extractor`、`exhaustive_matcher` 和 `mapper`。第一次使用清洗后的 5 张图, 第二次使用全部 6 张图并放宽 `Mapper.init_min_num_inliers`、`Mapper.abs_pose_r` 和三角化角度; 两次均报告 `No good initial image pair found`。补拍视频后, 我对官方 3DGS `convert.py` 做 COLMAP 3.6 兼容补丁, 移除不支持的 `--Mapper.ba_global_function_tolerance` 参数, 再用 90 张视频抽帧运行 COLMAP/undistort。最终 sparse model 注册 63 张图, 生成 3289 个稀疏点, 平均 track length 为 4.9085, 平均重投影误差为 0.8745 px。随后在 base 环境的 PyTorch 2.6.0+cu124 上训练 1000 iterations 3DGS, 并运行 render 与 metrics。

3.2 物体 B: 文本到 3D

threestudio 官方仓库已克隆, `launch.py --help` 能运行, 并确认存在 `configs/dreamfusion-sd.yaml`。计划 prompt 为:

a small yellow rubber duck toy, smooth plastic surface, single object, full body, centered, clean
3D asset, no text, no watermark

但完整训练依赖包含 `tiny-cuda-nn`、`nvdiffrast`、`xformers` 和扩散模型权重。本轮未完成独立 threestudio 环境安装和 SDS 训练。为了让题目一融合链路真实闭合, 我实现 `scripts/generate_proxy_assets.py` 根据同一 prompt 生成一个黄色鸭子 OBJ proxy mesh, 包含 2300 个顶点和 3964 个三角面, 并在合并阶段采样为 28000 个 Gaussian。该结果只作为文本到 3D 的可运行代理, 不作为官方 SDS 结果。

3.3 物体 C: 单图到 3D

已完成单图 RGBA 预处理,并把图像复制到 `third_party/threestudio/load/images/cup_rgba.png`, 后续可直接运行 `scripts/run_zero123_object_C.sh`。由于未完成 Zero123/Magic123 权重与训练, 本轮使用单图几何 proxy: 从 RGBA 前景估计主体颜色, 以圆柱杯身、杯盖和椭圆手柄先验生成 OBJ mesh, 包含 2284 个顶点和 4388 个三角面, 并采样为 36000 个 Gaussian。该结果是单图到 3D 的可运行代理, 不作为 Zero123 真实生成结果。

3.4 高斯级融合

工程中实现了 `mesh_to_gaussians.py`、`transform_gaussians.py`、`merge_gaussians.py` 和 `render_merged_path.py`。其中 mesh 转 Gaussian 按 3DGS PLY 字段写入 `f_dc`、`opacity`、`scale` 和单位四元数; 颜色使用 SH DC 约定 $(rgb - 0.5)/0.28209479$ 。融合时, 物体 A 使用真实 3DGS PLY; 物体 B/C 和背景 proxy mesh 先采样为 Gaussian, 再按 `configs/placements.yaml` 做缩放、旋转和平移, 最后按 PLY property 拼接为 `outputs/task1/merged_scene/point_cloud.ply`。CPU fallback renderer 使用 robust 取景和点云投影生成多视角漫游视频。

3.5 LeRobot ACT

LeRobot 仓库已克隆, 轻量依赖安装到 `local_pkgs/lerobot` 后, 源码方式的 `lerobot_train --help` 已跑通。真实 CALVIN 数据未下载时, 我实现了 `scripts/train_act_proxy.py` 作为 ACT-style 代理实验: 输入为视觉/状态向量, 输出为长度 8 的 action chunk, 损失为 Action L1。两个模型使用同一网络、batch size、learning rate、optimizer 和训练步数, 区别仅为训练域: ACT-A 只看 A, ACT-ABC 看 A/B/C, 再在 D 域做 zero-shot 代理评估。

4 实验设置

服务器硬件和软件探测见 `logs/system_info.txt`。提权环境下可见 3 张 NVIDIA RTX A6000, CUDA 12.4; base conda 中 PyTorch 为 2.6.0+cu124。PG 环境为 Python 3.12.9, 用于运行数据脚本。COLMAP 版本为 3.6, 无 CUDA。磁盘可用空间约为: 当前工作分区 492GB, /tmp 375GB。

第三方仓库 commit: 3DGS 为 54c035f7834b564019656c3e3fcc3646292f727d, threestudio 为 28d9d80d9d00f308244adfcf3be8b17ca0cb6465, LeRobot 为 2d7a42011a4f8e05a8c85d5fb908da258d4cc7b1, CALVIN 为 fa03f01f19c65920e18cf37398a9ce859274af76。

模块	设置项	取值
Object A 3DGS	输入	90 selected video frames, 63 registered
Object A 3DGS	训练步数 / 分辨率	1000 iterations, -r 2
Object A 3DGS	评估指标	PSNR 23.9658, SSIM 0.8707, LPIPS 0.2323
Gaussian fusion	合并规模	115133 Gaussians
ACT proxy	Network Architecture	2-layer MLP chunk policy, hidden dim 128
ACT proxy	Batch Size / LR / Optimizer	64 / 0.001 / AdamW
ACT proxy	Epochs or Steps	800 steps
ACT proxy	Loss Function	Action L1 Loss over chunk size 8
ACT proxy	Output weights	act_A_proxy.pt, act_ABC_proxy.pt

表 1: 主要实验设置与关键指标。

5 题目一结果

表 5 来自自动生成的 `report/tables/task1_assets.csv`。可以看到，本轮真正完成的是物体 A 视频版 3DGS、B/C/背景 proxy 资产、Gaussian 级融合和漫游视频；官方 SDS、Zero123 和 Mip-NeRF360 背景训练尚未完成，表中均以 proxy 标注。

□□□□□□□□□□□□□□□□	
3DGS deps	ready
Object A video SfM	success: 63/90 registered
Object A 3DGS	success: 1000 iter
Object B asset	proxy mesh+Gaussian done
Object C asset	RGBA+proxy mesh done
Background	proxy Gaussian done
Scene fusion	merged PLY+video done
threestudio	repo/config ready
CALVIN HF	splitA-D known; counts NA
ACT proxy	loss curves+weights done

图 4: 实验状态摘要，来自运行日志与文件存在性检查。

表 2: 题目一资产生成结果汇总。

Object A 3DGS test renders (top) and GT frames (bottom)




图 5: 物体 A 3DGS 测试集渲染预览。上排为 1000 iteration 渲染, 下排为对应 GT 帧。




图 6: A/B/C 与 counter-like 背景合并后的 Gaussian 点云漫游关键帧。完整视频见 `outputs/task1/videos/merged_scene_walkthrough.mp4`。

对三类资产生成方式的比较可以结合本轮真实观察：多视角重建对输入覆盖非常敏感，6 张照片失败，而连续视频抽帧成功；一旦 COLMAP 成功，几何和纹理最贴近真实物体，但耗时集中在 COLMAP/undistort。文本到 3D 不需要拍摄，prompt 可控，但官方 SDS 依赖和权重成本最高；本轮 proxy 鸭子几何稳定但语义和纹理都很简单。单图到 3D 只需一张照片，能保留正面外观，但背面、杯盖和提手需要模型先验补全；本轮 proxy 杯子保留了大体形状和黑色材质，但不具备 Zero123 多视角细节。

split	episodes	frames	action_dim	state_dim	camera_keys	task_count	env_distribution	status
train_A	NA	NA	NA	NA	NA	NA	splitA	remote_layout_only
train_ABC	NA	NA	NA	NA	NA	NA	splitA+splitB+splitC	remote_layout_only
test_D	NA	NA	NA	NA	NA	NA	splitD	remote_layout_only

表 3: CALVIN/LeRobot 数据切分探测结果。

6 题目二结果

Hugging Face 数据集探测输出见 `outputs/task2/calvin_split_summary.json` 和表 6。网页端已确认仓库顶层存在 `splitA`、`splitB`、`splitC`、`splitD`，因此脚本记录 `train_A=splitA`、`train_ABC=splitA+splitB+splitC`、`test_D=splitD`。但是服务器内 API 请求仍出现 `SOCKSHTTPConnectionPool` 与 `SSL EOF` 错误，没有下载 metadata，所以真实 CALVIN 的 `episodes`、`frames`、`action/state` 维度均保持 NA。

在代理实验中，WandB offline 日志写入 `outputs/task2/wandb/`，并导出图 7。两个模型同构同参：2 层 MLP chunk policy，hidden dim 128，chunk size 8，action dim 4，batch size 64，AdamW，learning rate 0.001，weight decay 0.0001，训练 800 steps，loss 为 Action L1。D 域评估见表 6：ACT-A 的 mean Action L1 为 0.3034，success rate 为 0.2383；ACT-ABC 的 mean Action L1 为 0.0409，success rate 为 1.0000。该结果说明在这个视觉 style 可观测的代理分布中，多环境训练能学到抵消背景偏移的映射；但它不是 CALVIN 真实机器人任务成功率。




图 7: ACT-style 代理实验的 Action L1 曲线。实线为训练集 loss，虚线为 D 域评估 loss。

model	metric_type	mean_action_l1	median_action_l1	success_rate	status	note
ACT-A	proxy_zero_shot_D	0.303447	0.306112	0.238281	proxy_run	Synthetic CALVIN-style visual distribution shift proxy; not a real CALVIN success
ACT-ABC	proxy_zero_shot_D	0.040896	0.038146	1.000000	proxy_run	Synthetic CALVIN-style visual distribution shift proxy; not a real CALVIN success

表 4: 环境 D zero-shot 代理评估结果。




图 8: D 域 zero-shot 代理评估对比。

从机制上看, ACT-A 只在环境 A 视觉分布上训练, 容易把背景 style 与动作映射绑定; ACT-ABC 混合多个环境后, 更容易学习环境不变的状态-动作关系。Action chunking 的优点是一次预测未来动作片段, 能减少逐步预测噪声; 风险是首帧视觉理解错误会影响整个 chunk。代理实验中 ACT-A 在 D 域 loss 长期维持高位, 正体现了这种视觉偏移下的 chunk 级误差放大。

7 讨论与局限性

本轮最大局限是输入、网络和时间预算。物体 A 的 6 张照片不足以完成 SfM, 但补拍视频说明连续视角覆盖能显著提升 COLMAP 成功率; 1000 iteration 3DGS 只是 sanity training, 渲染已成形但仍略模糊, 后续应延长到 7000–30000 iterations 并做更稳定的前景/背景控制。物体 B/C 和背景目前为代理资产, 能完成代码级 Gaussian 合并和视频输出, 但不具备官方 SDS、Zero123 或 Mip-NeRF360 训练结果的真实性。CALVIN 数据集的 split 布局已确认, 但元数据和样本未下载, 因此 ACT 表格是代理实验, 不应与真实 CALVIN success rate 横向比较。

8 结论

我完成了可复现工程框架、第三方仓库克隆、3DGS CUDA 扩展安装、LeRobot CLI 探测、物体 A 视频版 COLMAP+3DGS 训练、B/C/背景代理资产生成、Gaussian 级合并、漫游视频、ACT action chunking 代理训练、结果表、权重包和检查清单。严格意义上, 官方 SDS、Zero123、Mip-NeRF360 背景训练和真实 CALVIN ACT 训练仍需在网络与权重条件满足后继续跑; 当前工程已经把能真实补上的链路尽量补齐, 并在报告中区分了真实 3DGS 结果与代理结果。

参考文献

- [1] Jonathan T. Barron, Ben Mildenhall, Dor Verbin, Pratul P. Srinivasan, and Peter Hedman. Mip-nerf 360: Unbounded anti-aliased neural radiance fields. In *CVPR*, 2022.
- [2] Yuan-Chen Guo et al. threestudio: A unified framework for 3d content generation. <https://github.com/threestudio-project/threestudio>, 2023.
- [3] Hugging Face. Lerobot. <https://github.com/huggingface/lerobot>, 2024.
- [4] Bernhard Kerbl, Georgios Kopanas, Thomas Leimkuehler, and George Drettakis. 3d gaussian splatting for real-time radiance field rendering. *ACM Transactions on Graphics*, 2023.
- [5] Ruoshi Liu, Rundi Wu, Basile Van Hoorick, Pavel Tokmakov, Sergey Zakharov, and Carl Vondrick. Zero-1-to-3: Zero-shot one image to 3d object. In *ICCV*, 2023.
- [6] Oier Mees, Lukas Hermann, Erick Rosete-Beas, and Wolfram Burgard. Calvin: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks. In *IEEE Robotics and Automation Letters*, 2022.
- [7] Ben Poole, Ajay Jain, Jonathan T. Barron, and Ben Mildenhall. Dreamfusion: Text-to-3d using 2d diffusion. In *International Conference on Learning Representations*, 2023.
- [8] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *Robotics: Science and Systems*, 2023.