

基于 3DGS/AIGC 的多源资产融合与 ACT 跨环境泛化实验

姓名：张之蔚 学号：25210980169

课程：深度学习与空间智能

作业：期末作业

小组成员和分工：独立完成；本人完成主要实现、实验运行与报告整理。

GitHub 仓库链接：https://github.com/codenoobzzw/deeplearning_qimo.git。

模型权重网盘链接：<https://pan.baidu.com/s/1802o9Fr9d0nnt1CZjT-jNA?pwd=1111>，提取码：1111；当前本地权重包为 `outputs/weights/hw3_weights.zip`，包含 ACT 替代实验和真实 CALVIN 子集实验权重。

摘要

这次作业我围绕两个任务搭建了一个可复现实验工程：题目一完成多源 3D 资产生成、统一表示和场景融合；题目二完成 ACT 动作分块策略的跨环境泛化对比。物体 A 使用补拍环绕视频真实跑通 COLMAP+3DGS：90 张抽帧中注册 63 张，训练 1000 步后得到 19133 个 Gaussian，测试集 PSNR/SSIM/LPIPS 分别为 23.9658/0.8707/0.2323。受限于外部模型权重和大规模数据下载条件，threestudio SDS、Zero123 和 Mip-NeRF360 背景训练没有全部跑完；为尽量完成作业要求的完整链路，我补充实现了明确标注的替代实验：生成文本鸭子 mesh、单图杯子 mesh 和类 counter 背景 Gaussian，统一采样并合并为 115133 个高斯点，同时导出多视角漫游视频。题目二方面，我使用老师允许的数据源 `xiaoma26/calvin-lerobot` 下载了 splitA/B/C/D 每个环境 4 个真实 episode，并调用 LeRobot 源码中的 ACTPolicy 做离线 action chunking 子集实验：ACT-A 在 D 子集上的 mean Action L1 为 0.2779，ACT-ABC 为 0.2546。由于本轮没有完成 70GB 全量数据训练、视觉 CNN 输入训练和 CALVIN simulator rollout，报告中把“真实子集离线实验”和“替代 proxy 实验”分开说明，不把它们写成全量 CALVIN 成功率。

1 任务背景

3D Gaussian Splatting 将场景表示为显式高斯点云，具有训练和实时渲染效率高的优点 [4]。DreamFusion 使用预训练 2D 扩散模型和 SDS loss 从文本生成 3D 内容 [7]，threestudio 提供了统一实现框架 [2]。Zero-1-to-3 将单张图像拓展为多视角先验，可用于单图到 3D [5]。ACT 通过 action chunking 一次预测未来一段动作，减少逐步预测的高频抖动 [8]。LeRobot 和 CALVIN 为机器人模仿学习和跨环境泛化提供了工具与数据基础 [3, 6]。

我在实现时优先保证两点：第一，能真实运行的部分尽量跑出结果，而不是只写流程；第二，确实受限于网络、外部权重或数据集下载的部分，采用可复现的替代实验补齐工程链路，并在报告中明确标注。最终完成情况如下：

- 真实跑通: 物体 A 的 COLMAP+3DGS 重建、渲染和指标计算; CALVIN A/B/C/D 真实 parquet 子集下载与 LeRobot ACTPolicy 离线训练评估。
- 替代实现跑通: 物体 B/C mesh、背景 Gaussian、Gaussian 级场景融合、漫游视频、ACT 动作分块 proxy 曲线和 D 域评估。
- 未直接跑通: 官方 threestudio SDS、Zero123、Mip-NeRF360 背景训练, 以及全量视觉版 CALVIN ACT 与 simulator rollout, 原因主要是外部模型权重、全量数据规模和环境配置成本。

2 数据集与输入

物体 A 是笔记本电脑。最初输入为 6 张照片, 原始文件位于 `inputs/object_A/`; 这组照片视角覆盖不足, 因此主要用于记录失败对照。之后我补拍了 `inputs/object_A/A_video.mp4`, 时长约 15.43 秒, 共 460 帧。脚本 `scripts/extract_frames.py` 以 6 fps 抽帧并按清晰度、近重复阈值筛选, 最终从 93 个候选帧中保留 90 张, 写入 `data/object_A_video/input/`。图 1 和图 2 分别展示照片对照组与视频抽帧。

物体 C 是一张黑色保温杯照片, 位于 `inputs/object_C/cup.jpg`。由于当前 PG 环境没有现成的 rembg、SAM 或 OpenCV 包, 本实验使用纯 PIL/NumPy 的启发式前景掩膜, 生成 `outputs/task1/object_C_image3d/cup_rgba.png`。该结果保留了杯盖、白色提手和鸭子涂鸦, 但仍有部分桌面/鼠标垫背景残留, 见图 3。

Mip-NeRF 360 背景优先计划使用 counter 场景 [1], 但本轮没有完成大数据下载和背景训练; 为保证融合链路可运行, 我生成了一个类 counter 的背景替代 mesh 并采样为 Gaussian。CALVIN 数据使用 xiaoma26/calvin-lerobot¹。该仓库包含 `splitA`、`splitB`、`splitC`、`splitD` 四个顶层目录, 全量约 69.9GB; 本轮为了在时间内得到真实可复现结果, 每个 split 下载前 4 个 parquet episode 作为离线子集, 分别包含 215、236、260、260 帧, state 维度 15, action 维度 7。

¹<https://huggingface.co/datasets/xiaoma26/calvin-lerobot/tree/main>


Object A uploaded photos



00A.jpg



00A2.jpg



00A3.jpg



00A4.jpg



00A5.jpg



00A6.jpg

图 1: 物体 A 原始上传照片。实际只有 6 张, 视角数量和基线不足, 作为 COLMAP 失败对照。

Object A video frames used for successful COLMAP/3DGS




图 2: 物体 A 补拍视频抽帧预览。该组输入成功完成 COLMAP 稀疏重建与 3DGS 快速训练。




图 3: 物体 C 背景去除对比。右侧为启发式 RGBA 预览，可见完整杯子被保留，但边界和背景残留仍较粗。

3 方法

3.1 物体 A: COLMAP + 3DGS

我先用 6 张照片运行 CPU COLMAP 的特征提取、穷举匹配和建图流程。第一次使用清洗后的 5 张图，第二次使用全部 6 张图并放宽初始化内点数、绝对位姿内点数和三角化角度；两次均报告 No good initial image pair found。补拍视频后，我对官方 3DGS 的 `convert.py` 做 COLMAP 3.6 兼容补丁，移除该版本不支持的全局 BA 参数，再用 90 张视频抽帧运行 COLMAP/undistort。最终 sparse model 注册 63 张图，生成 3289 个稀疏点，平均 track length 为 4.9085，平均重投影误差为 0.8745 px。随后在 base 环境的 PyTorch 2.6.0+cu124 上训练 1000 步 3DGS，并运行渲染与指标计算。

3.2 物体 B: 文本到 3D

threestudio 官方仓库已克隆，help 命令能运行，并确认存在 DreamFusion 配置文件。计划提示词为：

a small yellow rubber duck toy, smooth plastic surface, single object, full body, centered, clean 3D asset, no text, no watermark

但完整训练依赖包含 `tiny-cuda-nn`、`nvdiffrast`、`xformers` 和扩散模型权重。本轮未完成独立 threestudio 环境安装和 SDS 训练。为了让题目一融合链路真实闭合，我实现 `scripts/generate_proxy_assets.py`，根据同一提示词生成一个黄色鸭子 OBJ 替代 mesh，包含 2300 个顶点和 3964 个三角面，并在合并阶段采样为 28000 个 Gaussian。该结果只作为文本到 3D 的可运行替代实现，不作为官方 SDS 结果。

3.3 物体 C：单图到 3D

已完成单图 RGBA 预处理，并把图像复制到 `third_party/threestudio/load/images/cup_rgba.png`，后续可直接运行 `scripts/run_zero123_object_C.sh`。由于未完成 Zero123/Magic123 权重与训练，本轮使用单图几何替代模型：从 RGBA 前景估计主体颜色，以圆柱杯身、杯盖和椭圆手柄先验生成 OBJ mesh，包含 2284 个顶点和 4388 个三角面，并采样为 36000 个 Gaussian。该结果是单图到 3D 的可运行替代实现，不作为 Zero123 真实生成结果。

3.4 高斯级融合

工程中实现了 `mesh_to_gaussians.py`、`transform_gaussians.py`、`merge_gaussians.py` 和 `render_merged_path.py`。其中 mesh 转 Gaussian 按 3DGS PLY 字段写入 `f_dc`、`opacity`、`scale` 和单位四元数；颜色使用 SH DC 约定 $(rgb - 0.5)/0.28209479$ 。融合时，物体 A 使用真实 3DGS PLY；物体 B/C 和背景替代 mesh 先采样为 Gaussian，再按 `configs/placements.yaml` 做缩放、旋转和平移，最后按 PLY property 拼接为 `outputs/task1/merged_scene/point_cloud.ply`。CPU 预览渲染器使用稳健取景和点云投影生成多视角漫游视频。

3.5 LeRobot ACT

LeRobot 仓库已克隆，轻量依赖安装到 `local_pkgs/lerobot` 后，源码方式的 `lerobot_train --help` 已跑通。根据数据集 split，我新增 `scripts/train_act_calvin_subset.py`：先下载真实 CALVIN-LeRobot parquet 子集，再读取 `state` 和 `actions`，调用 LeRobot 官方 ACTPolicy 训练长度为 8 的 action chunk。两个真实子集模型使用同一结构和超参数，区别仅为训练域：ACT-A-real-subset 只使用 splitA，ACT-ABC-real-subset 使用 splitA+B+C，最后统一在 splitD 子集上计算 Action L1。由于图像列读取在当前环境中会触发底层 `parquet/pyarrow` 崩溃，本轮真实子集实验使用 `state/environment_state` 输入，不是完整视觉 CNN ACT；另外我仍保留 `scripts/train_act_proxy.py` 作为 proxy 对照。

4 实验设置

服务器硬件和软件探测见 `logs/system_info.txt`。`nvidia-smi` 可见 3 张 NVIDIA RTX A6000，CUDA 12.4；base conda 中 PyTorch 为 2.6.0+cu124。PG 环境为 Python 3.12.9，用于运行数据脚本。COLMAP 版本为 3.6，无 CUDA。磁盘可用空间约为：当前工作分区 492GB，/tmp 375GB。

第三方仓库版本记录为：3DGS 54c035f，threestudio 28d9d80，LeRobot 2d7a420，CALVIN fa03f01。报告中使用短 commit 便于排版，完整工程保留在 `third_party/` 与 `local_pkgs/` 中。

模块	设置项	取值
物体 A 3DGS	输入	90 张视频抽帧, COLMAP 注册 63 张
物体 A 3DGS	训练步数 / 分辨率	1000 steps, -r 2
物体 A 3DGS	评估指标	PSNR 23.9658, SSIM 0.8707, LPIPS 0.2323
Gaussian 级融合	合并规模	115133 个 Gaussian
ACT 替代实验	网络结构	2 层 MLP 分块策略, hidden dim 128
ACT 替代实验	batch size / 学习率 / 优化器	64 / 0.001 / AdamW
ACT 替代实验	训练步数	800 steps
ACT 替代实验	损失函数	chunk size 8 上的 Action L1 Loss
ACT 替代实验	输出权重	act_A_proxy.pt, act_ABC_proxy.pt
CALVIN 真实子集 ACTPolicy	数据	A/B/C/D 每个 split 4 个真实 episode
CALVIN 真实子集 ACTPolicy	网络结构	LeRobot ACTPolicy, dim 64, 2 层 encoder, 1 层 decoder
CALVIN 真实子集 ACTPolicy	batch size / 学习率 / 优化器	16 / 0.0001 / AdamW
CALVIN 真实子集 ACTPolicy	训练步数 / chunk size	40 steps / 8
CALVIN 真实子集 ACTPolicy	输出权重	ACT-A-real-subset_real_calvin_subset.pt, ACT-ABC-real-subset_real_calvin_subset.pt

表 1: 主要实验设置与关键指标。

5 题目一结果

表 2 汇总了题目一的主要产物。更完整的自动记录保存在 report/tables/task1_assets.csv。可以看到，本轮真正跑通的是物体 A 视频版 3DGS、B/C/背景替代资产、Gaussian 级融合和漫游视频；官方 SDS、Zero123 和 Mip-NeRF360 背景训练尚未完成，因此对应行都明确写成“替代实现”。

□□□□□□□□□□□□□□□□

3DGS deps	ready
Object A video SfM	success: 63/90 registered
Object A 3DGS	success: 1000 iter
Object B asset	proxy mesh+Gaussian done
Object C asset	RGBA+proxy mesh done
Background	proxy Gaussian done
Scene fusion	merged PLY+video done
threestudio	repo/config ready
CALVIN HF	splitA-D known; counts NA
ACT proxy	loss curves+weights done

图 4: 实验状态摘要，来自运行日志与文件存在性检查。

Object A 3DGS test renders (top) and GT frames (bottom)




图 5: 物体 A 3DGS 测试集渲染预览。上排为训练 1000 步后的渲染结果，下排为对应 GT 帧。




图 6: A/B/C 与类 counter 背景合并后的 Gaussian 点云漫游关键帧。完整视频见 `outputs/task1/videos/merged_scene_walkthrough.mp4`。

资产	输入来源	实现路径	输出规模	质量观察
A	补拍环绕视频	COLMAP + 3DGS 真实训练	19133 个 Gaussian	视频抽帧后 COLMAP 成功注册 63 张图，渲染已能还原笔记本主体，但 1000 步训练仍略模糊。
B	文本提示词	threestudio 入口 + 文本替代 mesh	2300 顶点 / 28000 Gaussian	黄色鸭子语义清楚，适合做融合演示；但它不是官方 SDS 训练结果，纹理也比较简单。
C	单张杯子照片	RGBA 去背景 + 单图替代 mesh	2284 顶点 / 36000 Gaussian	杯身、杯盖和手柄形状被保留，细节依赖几何先验，不等同于 Zero123 多视角生成。
背景	counter 场景目标	类 counter 替代 Gaussian 背景	32000 个 Gaussian	提供桌面、墙面和空间尺度，保证 A/B/C 能在统一场景中插入和渲染。

表 2: 题目一资产生成与融合结果汇总。

对三类资产生成方式的比较可以结合本轮真实观察：多视角重建对输入覆盖非常敏感，6 张照片失败，而连续视频抽帧成功；一旦 COLMAP 成功，几何和纹理最贴近真实物体，但耗时集中在 COLMAP/undistort。文本到 3D 不需要拍摄，提示词可控，但官方 SDS 依赖和权重成本最高；本轮替代鸭子几何稳定但纹理很简单。单图到 3D 只需一张照片，能保留正面外观，但背面、杯盖和提手需要模型先验补全；本轮替代杯子保留了大体形状和黑色材质，但不具备 Zero123 多视角细节。

6 题目二结果

Hugging Face 数据集探测输出见 `outputs/task2/calvin_split_summary.json`，真实子集训练输出见 `outputs/task2/real_calvin_subset_summary.json`。最初脚本确实遇到过代理/SSL 问题，因此早期只记录了网页文件树；之后我根据作业提示重新访问 `xiaoma26/calvin-lerobot`，确认全量数据约 69.9GB，并下载了每个环境前 4 个 episode 做离线 ACTPolicy 子集实验。表 3 汇总本轮实际使用的数据。

使用方式	对应目录	子集规模	当前状态
训练 ACT-A	splitA	4 episodes / 215 frames	已下载 parquet; 用于 ACT-A-real-subset 训练。
训练 ACT-ABC	splitA +splitB +splitC	12 episodes / 711 frames	已下载 parquet; 用于 ACT-ABC-real-subset 训练。
测试 D 域	splitD	4 episodes / 260 frames	已下载 parquet; 用于 zero-shot Action L1 评估。

表 3: CALVIN/LeRobot 真实子集切分。state 维度为 15, action 维度为 7。

真实子集实验的训练曲线见图 7。两个模型都使用 LeRobot 源码中的 ACTPolicy, 输入为当前帧 state/environment_state, 输出为未来 8 步动作块, 损失为 Action L1。D 域评估见表 4: ACT-A-real-subset 的 mean Action L1 为 0.2779, ACT-ABC-real-subset 为 0.2546, 说明在这个小子集上混合 A/B/C 训练对 D 环境有一定帮助。由于只训练了 40 steps 且没有使用图像 CNN 和 simulator rollout, 这个数值应理解为离线动作误差, 不是 CALVIN 真实任务成功率。




图 7: 真实 CALVIN 子集 ACTPolicy 的 Action L1 曲线。实线为训练 loss, 虚线为 D 子集评估 loss。




图 8: 真实 CALVIN 子集 D 域离线评估对比。

模型	D mean L1	D median L1	L1<0.05	L1<0.10
ACT-A-real-subset	0.2779	0.2390	0.0000	0.0441
ACT-ABC-real-subset	0.2546	0.2263	0.0000	0.0441

表 4: D 域真实 CALVIN 子集离线评估结果。

另外，为了观察更清楚的视觉分布偏移现象，我保留了一个明确标注的 proxy 实验。WandB offline 日志写入 `outputs/task2/wandb/`，并导出图 9。两个 proxy 模型同构同参：2 层 MLP 分块策略，hidden dim 128，chunk size 8，action dim 4，batch size 64，AdamW，learning rate 0.001，weight decay 0.0001，训练 800 steps。D 域评估见表 5：ACT-A 的 mean Action L1 为 0.3034，ACT-ABC 的 mean Action L1 为 0.0409。该结果只用于解释 action chunking 在分布偏移下的现象，不代表真实 CALVIN 指标。




图 9: ACT 动作分块替代实验的 Action L1 曲线。实线为训练集 loss，虚线为 D 域评估 loss。




图 10: D 域 zero-shot 替代评估对比。

模型	D 域 mean Action L1	D 域 median Action L1	Success Rate
ACT-A	0.3034	0.3061	0.2383
ACT-ABC	0.0409	0.0381	1.0000

表 5: D 域 zero-shot 替代评估结果。数值来自本地 ACT 动作分块替代实验，不代表真实 CALVIN 成功率。

从机制上看，ACT-A 只在环境 A 上训练，遇到 D 环境时更容易过拟合单一场景的状态分布；

ACT-ABC 混合多个环境后，更容易学习跨场景共享的状态-动作关系。Action chunking 的优点是一次预测未来动作片段，能减少逐步预测噪声；风险是首帧理解错误会影响整个 chunk。真实子集实验中 ABC 的 D 域 Action L1 低于 A，proxy 实验中这种差距更加明显，二者方向一致，但真实子集仍太小，不能夸大为完整 CALVIN success rate 结论。

7 讨论与局限性

本轮最大局限是输入、网络和时间预算。物体 A 的 6 张照片不足以完成 SfM，但补拍视频说明连续视角覆盖能显著提升 COLMAP 成功率；1000 步 3DGS 属于快速训练，渲染已成形但仍略模糊，后续应延长到 7000-30000 steps，并做更稳定的前景/背景控制。物体 B/C 和背景目前为替代资产，能完成代码级 Gaussian 合并和视频输出，但不具备官方 SDS、Zero123 或 Mip-NeRF360 训练结果的真实性。CALVIN 方面已经下载真实 split 子集并训练 LeRobot ACTPolicy，但还不是全量 70GB 数据、不是图像 CNN 输入，也没有启动 CALVIN simulator 做任务成功率 rollout，因此只能作为真实数据离线 Action L1 结果。

8 复现与提交文件

工程根目录提供了 README.md、final_checklist.md 和分步骤脚本，报告中的图、表、权重包和视频均由工程目录内文件生成。主要提交物包括：

- 课程报告：report/report.pdf，对应源码为 report/main.tex。
- 题目一结果：outputs/task1/merged_scene/point_cloud.ply 和 outputs/task1/videos/merged_scene_walkthrough.mp4。
- 题目二权重：outputs/weights/hw3_weights.zip，其中包含 ACT-A/ACT-ABC proxy 权重和真实 CALVIN 子集 ACTPolicy 权重。
- 复现实验记录：outputs/task2/calvin_split_summary.json、outputs/task2/real_calvin_subset_summary.json、report/tables/*.csv、logs/*.log。

如果后续有更充足时间和磁盘，工程已经预留 scripts/run_threestudio_object_B.sh、scripts/run_zero123_object_C.sh 和 LeRobot/CALVIN 相关入口，可以继续把 B/C/背景替代资产替换为官方训练结果，并把当前 CALVIN 子集实验扩展为全量视觉 ACT 与 simulator rollout。

9 结论

我完成了可复现工程框架、第三方仓库克隆、3DGS CUDA 扩展安装、LeRobot CLI 探测、物体 A 视频版 COLMAP+3DGS 训练、B/C/背景替代资产生成、Gaussian 级合并、漫游视频、真实 CALVIN 子集 ACTPolicy 训练、ACT proxy 对照、结果表、权重包和检查清单。严格意义上，官方 SDS、Zero123、Mip-NeRF360 背景训练、全量视觉 ACT 和 CALVIN simulator 成功率仍需继续扩展；但当前工程已经把能真实补上的链路尽量补齐，并在报告中区分了真实 3DGS、真实 CALVIN 子集和替代结果。

参考文献

- [1] Jonathan T. Barron, Ben Mildenhall, Dor Verbin, Pratul P. Srinivasan, and Peter Hedman. Mip-nerf 360: Unbounded anti-aliased neural radiance fields. In *CVPR*, 2022.
- [2] Yuan-Chen Guo et al. threestudio: A unified framework for 3d content generation. <https://github.com/threestudio-project/threestudio>, 2023.
- [3] Hugging Face. Lerobot. <https://github.com/huggingface/lerobot>, 2024.
- [4] Bernhard Kerbl, Georgios Kopanas, Thomas Leimkuehler, and George Drettakis. 3d gaussian splatting for real-time radiance field rendering. *ACM Transactions on Graphics*, 2023.
- [5] Ruoshi Liu, Rundi Wu, Basile Van Hoorick, Pavel Tokmakov, Sergey Zakharov, and Carl Vondrick. Zero-1-to-3: Zero-shot one image to 3d object. In *ICCV*, 2023.
- [6] Oier Mees, Lukas Hermann, Erick Rosete-Beas, and Wolfram Burgard. Calvin: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks. In *IEEE Robotics and Automation Letters*, 2022.
- [7] Ben Poole, Ajay Jain, Jonathan T. Barron, and Ben Mildenhall. Dreamfusion: Text-to-3d using 2d diffusion. In *International Conference on Learning Representations*, 2023.
- [8] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *Robotics: Science and Systems*, 2023.