

基于 3DGS/AIGC 的多源资产融合与 ACT 跨环境泛化实验

姓名：待填写 学号：待填写

课程：深度学习与空间智能

作业：期末作业

小组成员和分工：待填写；若无其他成员，则为本人独立完成主要实现、实验运行与报告整理。

GitHub 仓库链接：待上传。

模型权重网盘链接：待上传；当前权重占位包为 `outputs/weights/hw3_weights.zip`。

摘要

本实验尝试完成两个任务：一是使用 COLMAP、3D Gaussian Splatting、threestudio/Zero123 系列方法构建多源 3D 资产并融合到真实背景中；二是使用 LeRobot 的 ACT 策略比较 CALVIN 环境 A 与 A/B/C 联合训练在未见环境 D 上的泛化。实现过程中，我搭建了完整工程目录、克隆了官方 3DGS/threestudio/LeRobot/CALVIN 仓库，安装并验证了 3DGS 的 CUDA 扩展和 LeRobot 训练 CLI。原始 6 张物体 A 照片因视角和基线不足导致 COLMAP 初始化失败；补拍的 `A_video.mp4` 成功抽取 90 张图，COLMAP 注册 63 张，1000 iteration 3DGS 生成 19133 个 Gaussian，测试集 PSNR/SSIM/LPIPS 分别为 23.9658/0.8707/0.2323。CALVIN 数据集网页已确认存在 `splitA-splitD`，但服务器内 Hugging Face API 仍受代理/SSL 错误影响，未下载元数据，因此 ACT 训练保持未运行状态，报告不编造 success rate。

1 任务背景

3D Gaussian Splatting 将场景表示为显式高斯点云，具有训练和实时渲染效率高的优点 [4]。DreamFusion 使用预训练 2D 扩散模型和 SDS loss 从文本生成 3D 内容 [7]，threestudio 提供了一实现框架 [2]。Zero-1-to-3 将单张图像拓展为多视角先验，可用于单图到 3D [5]。ACT 通过 action chunking 一次预测未来一段动作，减少逐步预测的高频抖动 [8]。LeRobot 和 CALVIN 为机器人模仿学习和跨环境泛化提供了工具与数据基础 [3, 6]。

2 数据集与输入

物体 A 是笔记本电脑。第一次输入为用户上传的 6 张照片，原始文件位于 `inputs/object_A/`；这组照片用于记录失败 baseline。之后补拍了 `inputs/object_A/A_video.mp4`，时长约 15.43 秒，共 460 帧。脚本 `scripts/extract_frames.py` 以 6 fps 抽帧并按清晰度、近重复阈值筛选，最终从 93 个候选帧中保留 90 张，写入 `data/object_A_video/input/`。图 1 和图 2 分别展示照片 baseline 与视频抽帧。

物体 C 是一张黑色保温杯照片，位于 `inputs/object_C/cup.jpg`。由于当前 PG 环境没有 rembg、SAM 或 OpenCV，本实验使用纯 PIL/NumPy 的启发式前景掩膜，生成 `outputs/task1/object_C_image3`。该结果保留了杯盖、白色提手和鸭子涂鸦，但仍有部分桌面/鼠标垫背景残留，见图 3。

Mip-NeRF 360 背景优先计划使用 counter 场景 [1], 但本轮没有完成数据下载和背景训练。CALVIN 数据优先计划使用 xiaoma26/calvin-lerobot¹。网页文件树可见 splitA、splitB、splitC、splitD 四个顶层目录; 服务器内 Hugging Face API 访问仍被代理/SSL 阻塞, 日志见 logs/calvin_hf_metadata_


Object A uploaded photos



00A.jpg




00A2.jpg



00A3.jpg



00A4.jpg



00A5.jpg




00A6.jpg


图 1: 物体 A 原始上传照片。实际只有 6 张, 视角数量和基线不足, 作为 COLMAP 失败 baseline。

¹<https://huggingface.co/datasets/xiaoma26/calvin-lerobot/tree/main>


Object A video frames used for successful COLMAP/3DGS




0001.jpg




0009.jpg




0017.jpg




0025.jpg




0033.jpg




0041.jpg






0050.jpg



0058.jpg



0066.jpg






图 3: 物体 C 背景去除对比。右侧为启发式 RGBA 预览, 可见完整杯子被保留, 但边界和背景残留仍较粗。

3 方法

3.1 物体 A: COLMAP + 3DGS

我先用 6 张照片运行 CPU COLMAP 的 `feature_extractor`、`exhaustive_matcher` 和 `mapper`。第一次使用清洗后的 5 张图, 第二次使用全部 6 张图并放宽 `Mapper.init_min_num_inliers`、`Mapper.abs_pose_r` 和三角化角度; 两次均报告 `No good initial image pair found`。补拍视频后, 我对官方 3DGS `convert.py` 做 COLMAP 3.6 兼容补丁, 移除不支持的 `--Mapper.ba_global_function_tolerance` 参数, 再用 90 张视频抽帧运行 COLMAP/undistort。最终 sparse model 注册 63 张图, 生成 3289 个稀疏点, 平均 track length 为 4.9085, 平均重投影误差为 0.8745 px。随后在 base 环境的 PyTorch 2.6.0+cu124 上训练 1000 iterations 3DGS, 并运行 render 与 metrics。

3.2 物体 B: 文本到 3D

threestudio 官方仓库已克隆, `launch.py --help` 能运行, 并确认存在 `configs/dreamfusion-sd.yaml`。计划 prompt 为:

a small yellow rubber duck toy, smooth plastic surface, single object, full body, centered, clean
3D asset, no text, no watermark

但完整训练依赖包含 `tiny-cuda-nn`、`nvdiffrast`、`xformers` 和扩散模型权重。本轮未完成独立 threestudio 环境安装和 SDS 训练, 因此没有文本生成 mesh。

3.3 物体 C: 单图到 3D

已完成单图 RGBA 预处理, 并把图像复制到 `third_party/threestudio/load/images/cup_rgba.png`, 后续可直接运行 `scripts/run_zero123_object_C.sh`。由于未完成 Zero123/Magic123 训练, 当前

没有杯子 mesh。

3.4 高斯级融合

工程中实现了 `mesh_to_gaussians.py`、`transform_gaussians.py`、`merge_gaussians.py` 和 `render_merged_path.py`。其中 mesh 转 Gaussian 按 3DGS PLY 字段写入 `f_dc`、`opacity`、`scale` 和单位四元数；颜色使用 SH DC 约定 $(rgb - 0.5)/0.28209479$ 。物体 A 已生成 Gaussian PLY，但物体 B/C mesh 与背景 3DGS 尚未完成，因此本轮没有生成 merged point cloud 或漫游视频。

3.5 LeRobot ACT

LeRobot 仓库已克隆，轻量依赖安装到 `local_pkgs/lerobot` 后，源码方式的 `lerobot_train --help` 已跑通。ACT 的关键思想是一次预测 action chunk，而不是单步动作；这可以减轻闭环执行中的短周期抖动，但在视觉分布偏移下也可能连续执行错误 chunk。

4 实验设置

服务器硬件和软件探测见 `logs/system_info.txt`。提权环境下可见 3 张 NVIDIA RTX A6000, CUDA 12.4；base conda 中 PyTorch 为 2.6.0+cu124。PG 环境为 Python 3.12.9，用于运行数据脚本。COLMAP 版本为 3.6，无 CUDA。磁盘可用空间约为：当前工作分区 492GB，`/tmp` 375GB。

第三方仓库 commit：3DGS 为 `54c035f7834b564019656c3e3fcc3646292f727d`，threestudio 为 `28d9d80d9d00f308244adfcf3be8b17ca0cb6465`，LeRobot 为 `2d7a42011a4f8e05a8c85d5fb908da258d4cc7b1`，CALVIN 为 `fa03f01f19c65920e18cf37398a9ce859274af76`。

5 题目一结果

表 5 来自自动生成的 `report/tables/task1_assets.csv`。可以看到，本轮真正完成的是工程搭建、物体 A 视频版 3DGS、物体 C RGBA 预处理、3DGS 依赖安装和 LeRobot CLI 探测；没有完成 SDS mesh、Zero123 mesh、背景 3DGS 和多资产融合。

□□□□□□□□□□□□□□□□	
3DGS deps	ready
Object A video SfM	success: 63/90 registered
Object A 3DGS	success: 1000 iter
Object C RGBA	heuristic done
threestudio	repo/config ready
CALVIN HF	splitA-D known; counts NA
LeRobot CLI	help ready

图 4: 实验状态摘要，来自运行日志与文件存在性检查。

chunking 也有风险：如果第一帧视觉理解错误，后续一整段 chunk 都可能偏离。上述分析需要以后续真实训练曲线和 D 环境指标验证，本轮不把它写成实验结论。

7 讨论与局限性

本轮最大局限是输入、网络和时间预算。物体 A 的 6 张照片不足以完成 SfM，但补拍视频说明连续视角覆盖能显著提升 COLMAP 成功率；1000 iteration 3DGS 只是 sanity training，渲染已成形但仍略模糊，后续应延长到 7000–30000 iterations 并做更稳定的前景/背景控制。物体 C 的 RGBA 只是启发式，适合作为后续 Zero123 输入草稿，但不是高质量背景去除。CALVIN 数据集的 split 布局已确认，但元数据和样本未下载，因此无法启动 ACT 训练。threestudio 依赖体积较大，需要单独环境和模型权重下载，本轮没有继续强行安装训练。

8 结论

我完成了可复现工程框架、第三方仓库克隆、3DGS CUDA 扩展安装、LeRobot CLI 探测、物体 A/C 输入整理、物体 A 视频版 COLMAP+3DGS 训练、结果表和检查清单生成。物体 A 已得到可检查的 Gaussian PLY 与渲染指标；物体 B/C 的 3D mesh、背景 3DGS、融合视频和 ACT 训练仍未完成，报告和 README 均按真实状态记录。下一步最有效的改进是延长物体 A 训练、补齐 B/C/背景资产，并修复 Hugging Face 访问后下载 CALVIN split 元数据再跑 ACT-A 与 ACT-ABC 对比。

参考文献

- [1] Jonathan T. Barron, Ben Mildenhall, Dor Verbin, Pratul P. Srinivasan, and Peter Hedman. Mip-nerf 360: Unbounded anti-aliased neural radiance fields. In *CVPR*, 2022.
- [2] Yuan-Chen Guo et al. threestudio: A unified framework for 3d content generation. <https://github.com/threestudio-project/threestudio>, 2023.
- [3] Hugging Face. Lerobot. <https://github.com/huggingface/lerobot>, 2024.
- [4] Bernhard Kerbl, Georgios Kopanas, Thomas Leimkuehler, and George Drettakis. 3d gaussian splatting for real-time radiance field rendering. *ACM Transactions on Graphics*, 2023.
- [5] Ruoshi Liu, Rundi Wu, Basile Van Hoorick, Pavel Tokmakov, Sergey Zakharov, and Carl Vondrick. Zero-1-to-3: Zero-shot one image to 3d object. In *ICCV*, 2023.
- [6] Oier Mees, Lukas Hermann, Erick Rosete-Beas, and Wolfram Burgard. Calvin: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks. In *IEEE Robotics and Automation Letters*, 2022.
- [7] Ben Poole, Ajay Jain, Jonathan T. Barron, and Ben Mildenhall. Dreamfusion: Text-to-3d using 2d diffusion. In *International Conference on Learning Representations*, 2023.

- [8] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *Robotics: Science and Systems*, 2023.