

基于 3DGS/AIGC 的多源资产融合与 ACT 跨环境泛化实验

姓名：张之蔚 学号：25210980169

课程：深度学习与空间智能
期末作业

小组成员：独立完成。

GitHub 仓库链接：https://github.com/codenoobzzw/deeplearning_qimo.git。

模型权重网盘链接：<https://pan.baidu.com/s/1802o9Fr9d0nnt1CZjT-jNA?pwd=1111>，提取码：1111。

本地权重包：outputs/weights/hw3_weights.zip。

摘要

本次作业我围绕“多源 3D 资产融合”和“ACT 跨环境泛化”做了一个可复现工程。任务一中，物体 A 使用自己补拍的视频真实跑通 COLMAP+3DGS，90 张抽帧中注册 63 张，1000 step 后测试集 PSNR/SSIM/LPIPS 为 23.9658/0.8707/0.2323。物体 B 按题目要求走了 threestudio DreamFusion/SDS 的官方训练入口，并用预训练 tiny Stable Diffusion 模型完成 1 step 烟测；物体 C 使用我拍摄的单张杯子图，先去背景，再用 stable-Zero123 官方权重完成 1 step 烟测。背景部分下载了官方 Mip-NeRF360 counter 场景，使用其 COLMAP sparse model 跑 3DGS 1000 step，得到 PSNR/SSIM/LPIPS 为 24.5242/0.8315/0.1954。最后我把 A/B/C 放进真实 counter 背景并生成了多视角漫游视频。

任务二中，我使用 xiaoma26/calvin-1erobot 数据集下载 splitA/B/C/D 每个 split 的前 4 个真实 parquet episode，训练了 LeRobot 官方 ACTPolicy。其中视觉版 ACT 输入包括 state、主相机图像和腕部相机图像；ACT-A 和 ACT-ABC 使用同一网络结构和超参数，在未见过的 splitD 上做离线 Action L1 评估。因为全量 CALVIN 约 70GB，且 simulator rollout 环境较重，本报告没有把小规模离线结果写成完整任务成功率，而是明确记录实验边界。

1 作业要求对照

我先把老师给的要求逐项整理成表 1。整体来说，A、背景、融合视频和 Task2 的真实 LeRobot ACT 子集实验已经实际跑过；B/C 的官方链路也已经跑到 1 step 烟测，但由于完整 SDS/Zero123 长训练成本较高，最终用于融合展示的 B/C 资产仍采用可复现的代理 mesh。

要求	当前状态	说明
物体 A 多视角/视频 3DGS	已完成	使用 <code>inputs/object_A/A_video.mp4</code> 抽帧，COLMAP 注册 63/90 张图，3DGS 训练 1000 step。
物体 B 文本到 3D SDS	已跑通入口	使用 threestudio DreamFusion/SDS 官方入口和预训练 tiny SD 模型完成 1 step；融合资产为同提示词生成的鸭子 proxy mesh。
物体 C 单图 Zero123	已跑通入口	对杯子图去背景，下载 stable-Zero123 权重并完成 1 step；融合资产为基于单图外观的杯子 proxy mesh。
开源背景 3DGS	已完成	下载 Mip-NeRF360 counter，使用官方 sparse/0 训练 3DGS 1000 step 并计算指标。
A/B/C 插入背景并渲染视频	已完成	输出 <code>outputs/task1/videos/merged_scene_counter_walkthrough.mp4</code> ，合并点云 293755 个 Gaussian。
多视角/文本/单图比较	已完成	在任务一讨论中比较几何、纹理、计算量与融合方式。
CALVIN ACT-A baseline	已完成	使用真实 splitA 子集训练 LeRobot ACTPolicy。
CALVIN A/B/C 混合训练	已完成	使用 splitA+B+C 子集，同架构同超参训练 ACT-ABC。
未见 D 环境评估	已完成	在 splitD 子集上计算 Action L1、median L1 和阈值成功比例。

表 1: 作业要求完成情况对照。

2 任务一：多源 3D 资产与融合

2.1 输入数据

物体 A 是我拍摄的笔记本电脑。最开始只有 6 张照片，COLMAP 两次尝试都报 `No good initial image pair found`，说明视角数量和相邻重叠不够。后面我补拍了 `A_video.mp4`，用脚本从视频中筛出 90 张较清晰、重复度较低的帧。物体 C 是我拍摄的一张黑色杯子照片，先用 PIL/NumPy 做启发式去背景，结果如图 1 所示。

Object A video frames used for successful COLMAP/3DGS



图 1: 左：物体 A 视频抽帧预览；右：物体 C 单图去背景结果。

2.2 物体 A：COLMAP + 3DGS

物体 A 的流程是官方 3DGS 路线：先用 COLMAP 做特征提取、匹配、稀疏重建和 undistort，再用 gaussian-splatting 训练。视频抽帧后 COLMAP 注册 63 张图，稀疏点数为 3289，平均重投影误差为 0.8745 px。3DGS 快速训练 1000 step 后得到 19133 个 Gaussian。渲染预览见图 2。

Object A 3DGS test renders (top) and GT frames (bottom)




图 2: 物体 A 3DGS 测试集渲染预览。上排为渲染结果, 下排为对应 GT 帧。

2.3 物体 B/C: AIGC 官方入口与融合资产

物体 B 的提示词是 “a small yellow rubber duck toy”。我在 threestudio 中使用 DreamFusion/SDS 配置启动训练。由于服务器直连 HuggingFace 的稳定性不好, 完整 SD2.1 权重没有稳定拿到; 为了确认官方 SDS 代码路径确实能跑, 我使用 `hf-internal-testing/tiny-stable-diffusion-pipe` 完成 1 step 训练和测试视频输出。该实验不是高质量文本到 3D 成品, 但它实际调用了 threestudio 的 prompt processor、diffusion guidance 和 SDS 训练过程。

物体 C 使用 stable-Zero123 官方权重 `stable_zero123.ckpt`, 输入为去背景后的 `cup_rgba.png`, 同样完成 1 step 训练、val/test 视频输出。B/C 由于只跑了烟测, 几何质量不足以直接作为最终融合模型, 所以我另外生成了可复现的 proxy mesh: 黄色鸭子 mesh 2300 顶点/3964 面, 杯子 mesh 2284 顶点/4388 面, 再采样成 Gaussian 参与融合。图 3 展示官方烟测输出。



图 3: 左: threestudio DreamFusion/SDS 1-step 输出; 右: stable-Zero123 1-step 训练图像输出。

2.4 Mip-NeRF360 背景 3DGS

背景采用 Mip-NeRF360 官方 counter 场景 [1]。我下载 360_v2.zip 后只解压 counter/ 子目录，共 240 张图，且数据集自带 sparse/0。使用 gaussian-splatting 训练 1000 step，初始化点数 155767，最终保存 210622 个 Gaussian。渲染和指标也跑完了，测试集 PSNR/SSIM/LPIPS 为 24.5242/0.8315/0.1954。图 4 是测试视角的渲染结果。



图 4: Mip-NeRF360 counter 背景 3DGS 1000 step 渲染结果。

2.5 统一表示与场景融合

融合时我把 3DGS 的 PLY 作为统一表示。物体 A 和背景直接使用训练得到的 Gaussian；B/C 的 proxy mesh 先采样为 Gaussian，再写成与 3DGS 相同的 PLY 字段，包括位置、颜色 SH DC、opacity、scale 和 rotation。随后使用 configs/placements_official_counter.yaml 对 A/B/C 做缩放、旋转和平移，并与 counter 背景拼接为一个点云。最终 official-counter 版合并点云包含 293755 个 Gaussian，输出为 outputs/task1/merged_scene_counter/point_cloud.ply。CPU 预览渲染器生成的关键帧见图 5，视频为 outputs/task1/videos/merged_scene_counter_walkthrough.mp4。



图 5: A/B/C 插入 Mip-NeRF360 counter 背景后的多视角漫游关键帧。这里是 CPU 点云预览，主要用于确认空间融合关系。

资产	输入与方法	输出规模	观察
A	自拍视频, COLMAP+3DGS	19133 Gaussian	真实重建效果最好, 但对拍摄视角覆盖很敏感。
B	文本提示词, three-studio SDS 1-step + proxy mesh	28000 sampled Gaussian	文本生成不需要拍摄, 语义可控; 完整 SDS 长训练成本最高。
C	单张杯子图, 去背景 + Zero123 1-step + proxy mesh	36000 sampled Gaussian	单图输入方便, 但背面和厚度依赖模型或几何先验。
背景	Mip-NeRF360 counter, 3DGS 1000 step	210622 Gaussian	开源场景几何稳定, 适合承载插入物体。

表 2: 任务一主要资产结果。

从比较上看, 多视角 3DGS 对真实几何和纹理最可靠, 但需要足够视角, 6 张图明显不够; 文本到 3D 的优势是从提示词直接生成物体, 缺点是依赖扩散权重和较长优化; 单图到 3D 的门槛最低, 但背面补全更依赖先验。三者最后都转成 Gaussian/PLY 后, 合并渲染就变成同一套显式点云表示上的变换、拼接和相机路径渲染。

3 任务二：LeRobot ACT 跨环境泛化

3.1 数据与设置

任务二使用 HuggingFace 数据集 xiaoma26/calvin-lerobot。我下载了 splitA/B/C/D 每个 split 前 4 个 parquet episode, 帧数分别为 215、236、260、260。每帧包含 15 维 state、7 维 action、主视角图像和 wrist image。全量数据约 70GB, 本实验是课程时间内可复现的小规模真实子集实验。

我训练了两类 LeRobot ACTPolicy[2, 3]。第一类是 state-only 子集实验, 用来快速验证 ACT action chunking; 第二类是更贴近题目要求的视觉版 ACT, 输入为 state + image + wrist_image, 视觉 backbone 为 ResNet18, chunk size 为 8。ACT-A 只用 splitA 训练, ACT-ABC 用 splitA+B+C 训练, 二者网络和超参数完全一致, 最后都在未见过的 splitD 上做 zero-shot 离线 Action L1 评估。

设置	state-only ACT	visual ACT
训练数据	A 或 A+B+C, 每 split 4 episodes	同左
输入	state/environment_state	state + main image + wrist image
图像尺寸	无	64 × 64
chunk size / stride	8 / 4	8 / 4
batch size	16	8
训练步数	40	30
模型宽度	dim 64, 2 encoder, 1 decoder	dim 64, ResNet18 backbone, 2 encoder, 1 decoder

表 3: CALVIN 子集 ACT 实验超参数。

3.2 结果

state-only 真实子集结果见表 4。ACT-ABC 在 splitD 上的 mean Action L1 从 0.2779 降到 0.2546, median L1 也略有下降, 说明混合 A/B/C 对未见 D 有一定帮助。

模型	D mean L1	D median L1	L1<0.05	L1<0.10
ACT-A-real-subset	0.2779	0.2390	0.0000	0.0441
ACT-ABC-real-subset	0.2546	0.2263	0.0000	0.0441

表 4: state-only ACT 在 splitD 上的离线评估。

视觉 ACT 是本次补上的重点, 曲线和 D 域结果见图 6 与表 5。这个实验里 ACT-ABC 的 mean L1 比 ACT-A 略高, 但 median L1 更低, 并且 L1<0.10 的比例从 0 提高到 0.0735。我对这个结果的理解是: 小数据、短训练和随机初始化视觉 backbone 会让 mean L1 有噪声, 但混合环境训练确实改善了一部分较容易样本的动作误差尾部。这个现象也符合 ACT 的特点: action chunking 可以减少逐步预测的抖动, 但如果第一帧视觉理解受环境分布偏移影响, 整个动作块都会被带偏。




图 6: 视觉 ACT 真实 CALVIN 子集训练曲线与 splitD 离线评估。

模型	D mean L1	D median L1	L1<0.05	L1<0.10
ACT-A-visual-real-subset	0.2783	0.2636	0.0000	0.0000
ACT-ABC-visual-real-subset	0.2865	0.2355	0.0000	0.0735

表 5: visual ACT 在 splitD 上的离线评估。该表不是 simulator rollout 成功率。

此外，我保留了一个明确标注的 proxy 实验，用来更直观地展示分布偏移下 ACT-A 和 ACT-ABC 的差异。该实验有 WandB offline 日志，导出曲线在 `report/figs/act_action_l1_loss.png`。它不代表真实 CALVIN 指标，只作为辅助解释：单环境训练更容易过拟合 A 域，混合 A/B/C 后对 D 域的动作误差更稳。

4 复现与提交文件

工程中的主要复现入口如下：

- 物体 A: `scripts/train_3dgs_object.sh`
- 物体 B SDS 烟测: `scripts/run_threestudio_object_B_smoke.sh`
- 物体 C Zero123 烟测: `scripts/run_zero123_object_C_smoke.sh`
- 背景 3DGS: `SCENE=counter ITERATIONS=1000 RESOLUTION="-r 8" bash scripts/train_3dgs_background.sh`
- 官方背景融合: `configs/placements_official_counter.yaml`, `scripts/merge_gaussians.py`, `scripts/render_merged_path.py`
- 视觉 ACT: `scripts/train_act_calvin_visual_subset.py`

主要提交结果包括：

- 报告 PDF: `report/report.pdf`
- 任务一视频: `outputs/task1/videos/merged_scene_counter_walkthrough.mp4`
- 任务一合并点云: `outputs/task1/merged_scene_counter/point_cloud.ply`
- 任务二表格: `report/tables/task2_visual_calvin_eval_D.csv`
- 权重包: `outputs/weights/hw3_weights.zip`
- 最终检查清单: `final_checklist.md`

5 总结

这次作业里我真正跑通了物体 A 的 3DGS、官方 Mip-NeRF360 背景 3DGS、A/B/C/背景的 Gaussian 级融合、真实 CALVIN 子集上的 LeRobot ACT 训练和 D 环境评估。B/C 的 SDS 与 Zero123 由于完整长训练成本较高，目前做到官方入口 1 step 烟测，并用 proxy mesh 支撑最终融合展示。我觉得这个工程的主要价值是把作业每个环节都落到了可执行脚本、日志、图表和权重文件

上；不足之处也比较明确：如果继续做，可以把 B/C 的 1 step 烟测扩展到正式长训练，把 CALVIN 从 4 episode/split 扩到更大规模，并接入 simulator rollout success rate。

参考文献

- [1] Jonathan T. Barron, Ben Mildenhall, Dor Verbin, Pratul P. Srinivasan, and Peter Hedman. Mip-nerf 360: Unbounded anti-aliased neural radiance fields. In *CVPR*, 2022.
- [2] Hugging Face. Lerobot. <https://github.com/huggingface/lerobot>, 2024.
- [3] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *Robotics: Science and Systems*, 2023.