

# 基于 3DGS/AIGC 的多源资产融合与 ACT 跨环境泛化实验

姓名：张之蔚 学号：25210980169

课程：深度学习与空间智能  
期末作业

小组成员：独立完成。

## 摘要

本次作业我围绕“多源 3D 资产融合”和“ACT 跨环境泛化”做了两个实验。任务一中，物体 A 使用自己补拍的视频真实跑通 COLMAP+3DGS，90 张抽帧中注册 63 张，1000 step 后测试集 PSNR/SSIM/LPIPS 为 23.9658/0.8707/0.2323。物体 B 使用 threestudio DreamFusion/SDS 的训练入口，并用预训练 tiny Stable Diffusion 模型完成 1 step 烟测；物体 C 使用我拍摄的单张杯子图，先去背景，再用 stable-Zero123 官方权重完成 1 step 烟测。背景部分下载了官方 Mip-NeRF360 counter 场景，使用其 COLMAP sparse model 跑 3DGS 1000 step，得到 PSNR/SSIM/LPIPS 为 24.5242/0.8315/0.1954。最后我把 A/B/C 放进真实 counter 背景并生成了多视角漫游视频。

任务二中，我使用 xiaoma26/calvin-lerobot 数据集下载 splitA/B/C/D 每个 split 的前 4 个真实 parquet episode，训练了 LeRobot 官方 ACTPolicy。其中视觉版 ACT 输入包括 state、主相机图像和腕部相机图像；ACT-A 和 ACT-ABC 使用同一网络结构和超参数，在未见过的 splitD 上做离线 Action L1 评估。因为全量 CALVIN 约 70GB，且 simulator rollout 环境较重，本文没有把小规模离线结果写成完整任务成功率，而是明确记录实验边界。

## 1 任务一：多源 3D 资产与融合

### 1.1 输入数据

物体 A 是我拍摄的笔记本电脑。最开始只有 6 张照片，COLMAP 两次尝试都报 No good initial image pair found，说明视角数量和相邻重叠不够。后面我补拍了 A\_video.mp4，用脚本从视频中筛出 90 张较清晰、重复度较低的帧。物体 C 是我拍摄的一张黑色杯子照片，先用 PIL/NumPy 做启发式去背景，结果如图 1 所示。

Object A video frames used for successful COLMAP/3DGS




图 1: 左：物体 A 视频抽帧预览；右：物体 C 单图去背景结果。

## 1.2 物体 A：COLMAP + 3DGS

物体 A 的流程是官方 3DGS 路线：先用 COLMAP 做特征提取、匹配、稀疏重建和 undistort，再用 gaussian-splatting 训练。视频抽帧后 COLMAP 注册 63 张图，稀疏点数为 3289，平均重投影误差为 0.8745 px。3DGS 快速训练 1000 step 后得到 19133 个 Gaussian。渲染预览见图 2。

Object A 3DGS test renders (top) and GT frames (bottom)




图 2: 物体 A 3DGS 测试集渲染预览。上排为渲染结果，下排为对应 GT 帧。

### 1.3 物体 B/C: AIGC 官方入口与融合资产

物体 B 的提示词是 “a small yellow rubber duck toy”。我在 threestudio 中使用 DreamFusion/SDS 配置启动训练。由于服务器直连 HuggingFace 的稳定性不好，完整 SD2.1 权重没有稳定拿到；为了确认官方 SDS 代码路径确实能跑，我使用 `hf-internal-testing/tiny-stable-diffusion-pipe` 完成 1 step 训练和测试视频输出。该实验不是高质量文本到 3D 成品，但它实际调用了 threestudio 的 prompt processor、diffusion guidance 和 SDS 训练过程。

物体 C 使用 stable-Zero123 官方权重 `stable_zero123.ckpt`，输入为去背景后的 `cup_rgba.png`，同样完成 1 step 训练、val/test 视频输出。B/C 由于只跑了烟测，几何质量不足以直接作为最终融合模型，所以我另外生成了固定的 proxy mesh：黄色鸭子 mesh 2300 顶点/3964 面，杯子 mesh 2284 顶点/4388 面，再采样成 Gaussian 参与融合。图 3 展示官方烟测输出。



图 3: 左: threestudio DreamFusion/SDS 1-step 输出；右: stable-Zero123 1-step 训练图像输出。

## 1.4 Mip-NeRF360 背景 3DGS

背景采用 Mip-NeRF360 官方 counter 场景 [1]。我下载 360\_v2.zip 后只解压 counter/ 子目录，共 240 张图，且数据集自带 sparse/0。使用 gaussian-splatting 训练 1000 step，初始化点数 155767，最终保存 210622 个 Gaussian。渲染和指标也跑完了，测试集 PSNR/SSIM/LPIPS 为 24.5242/0.8315/0.1954。图 4 是测试视角的渲染结果。



图 4: Mip-NeRF360 counter 背景 3DGS 1000 step 渲染结果。

## 1.5 统一表示与场景融合

融合时我把 3DGS 的 PLY 作为统一表示。物体 A 和背景直接使用训练得到的 Gaussian；B/C 的 proxy mesh 先采样为 Gaussian，再写成与 3DGS 相同的 PLY 字段，包括位置、颜色 SH DC、opacity、scale 和 rotation。随后对 A/B/C 做缩放、旋转和平移，并与 counter 背景拼接为一个点云。最终 official-counter 版合并点云包含 293755 个 Gaussian，并生成了多视角漫游视频。CPU 预览渲染器生成的关键帧见图 5。



图 5: A/B/C 插入 Mip-NeRF360 counter 背景后的多视角漫游关键帧。这里是 CPU 点云预览，主要用于确认空间融合关系。

| 资产 | 输入与方法                                       | 输出规模                   | 观察                               |
|----|---------------------------------------------|------------------------|----------------------------------|
| A  | 自拍视频, COLMAP+3DGS                           | 19133 Gaussian         | 真实重建效果最好, 但对拍摄视角覆盖很敏感。           |
| B  | 文本提示词, three-studio SDS 1-step + proxy mesh | 28000 sampled Gaussian | 文本生成不需要拍摄, 语义可控; 完整 SDS 长训练成本最高。 |
| C  | 单张杯子图, 去背景 + Zero123 1-step + proxy mesh    | 36000 sampled Gaussian | 单图输入方便, 但背面和厚度依赖模型或几何先验。         |
| 背景 | Mip-NeRF360 counter, 3DGS 1000 step         | 210622 Gaussian        | 开源场景几何稳定, 适合承载插入物体。              |

表 1: 任务一主要资产结果。

从比较上看, 多视角 3DGS 对真实几何和纹理最可靠, 但需要足够视角, 6 张图明显不够; 文本到 3D 的优势是从提示词直接生成物体, 缺点是依赖扩散权重和较长优化; 单图到 3D 的门槛最低, 但背面补全更依赖先验。三者最后都转成 Gaussian/PLY 后, 合并渲染就变成同一套显式点云表示上的变换、拼接和相机路径渲染。

## 2 任务二：LeRobot ACT 跨环境泛化

### 2.1 数据与设置

任务二使用 HuggingFace 数据集 `xiaoma26/calvin-lerobot`。我下载了 splitA/B/C/D 每个 split 前 4 个 parquet episode, 帧数分别为 215、236、260、260。每帧包含 15 维 state、7 维 action、主视角图像和 wrist image。全量数据约 70GB, 因此本实验使用课程时间内可以完成的小规模真实子集。

我训练了两类 LeRobot ACTPolicy[2, 3]。第一类是 state-only 子集实验, 用来快速验证 ACT action chunking; 第二类是更贴近题目要求的视觉版 ACT, 输入为 `state + image + wrist_image`, 视觉 backbone 为 ResNet18, chunk size 为 8。ACT-A 只用 splitA 训练, ACT-ABC 用 splitA+B+C 训练, 二者网络和超参数完全一致, 最后都在未见过的 splitD 上做 zero-shot 离线 Action L1 评估。



| 设置                  | state-only ACT                | visual ACT                                      |
|---------------------|-------------------------------|-------------------------------------------------|
| 训练数据                | A 或 A+B+C, 每 split 4 episodes | 同左                                              |
| 输入                  | state/environment_state       | state + main image + wrist image                |
| 图像尺寸                | 无                             | 64 × 64                                         |
| chunk size / stride | 8 / 4                         | 8 / 4                                           |
| batch size          | 16                            | 8                                               |
| 训练步数                | 40                            | 30                                              |
| 模型宽度                | dim 64, 2 encoder, 1 decoder  | dim 64, ResNet18 backbone, 2 encoder, 1 decoder |

表 2: CALVIN 子集 ACT 实验超参数。

## 2.2 结果

state-only 真实子集结果见表 3。ACT-ABC 在 splitD 上的 mean Action L1 从 0.2779 降到 0.2546, median L1 也略有下降, 说明混合 A/B/C 对未见 D 有一定帮助。

| 模型                  | D mean L1 | D median L1 | L1<0.05 | L1<0.10 |
|---------------------|-----------|-------------|---------|---------|
| ACT-A-real-subset   | 0.2779    | 0.2390      | 0.0000  | 0.0441  |
| ACT-ABC-real-subset | 0.2546    | 0.2263      | 0.0000  | 0.0441  |

表 3: state-only ACT 在 splitD 上的离线评估。

视觉 ACT 是本次补上的重点, 曲线和 D 域结果见图 6 与表 4。这个实验里 ACT-ABC 的 mean L1 比 ACT-A 略高, 但 median L1 更低, 并且 L1<0.10 的比例从 0 提高到 0.0735。我对这个结果的理解是: 小数据、短训练和随机初始化视觉 backbone 会让 mean L1 有噪声, 但混合环境训练确实改善了一部分较容易样本的动作误差尾部。这个现象也符合 ACT 的特点: action chunking 可以减少逐步预测的抖动, 但如果第一帧视觉理解受环境分布偏移影响, 整个动作块都会被带偏。




图 6: 视觉 ACT 真实 CALVIN 子集训练曲线与 splitD 离线评估。

| 模型                         | D mean L1 | D median L1 | L1<0.05 | L1<0.10 |
|----------------------------|-----------|-------------|---------|---------|
| ACT-A-visual-real-subset   | 0.2783    | 0.2636      | 0.0000  | 0.0000  |
| ACT-ABC-visual-real-subset | 0.2865    | 0.2355      | 0.0000  | 0.0735  |

表 4: visual ACT 在 splitD 上的离线评估。该表不是 simulator rollout 成功率。

此外，我保留了一个明确标注的 proxy 实验，用来更直观地展示分布偏移下 ACT-A 和 ACT-ABC 的差异。该实验有 WandB offline 日志，导出曲线在 `report/figs/act_action_l1_loss.png`。它不代表真实 CALVIN 指标，只作为辅助解释：单环境训练更容易过拟合 A 域，混合 A/B/C 后对 D 域的动作误差更稳。

### 3 总结与不足

通过任务一的实验，我感受到多视角重建和单图/文本生成的侧重点不一样。多视角 3DGS 最依赖拍摄质量，最初 6 张照片失败，补拍视频后才稳定完成 SfM 和 Gaussian 训练；文本到 3D 和单图到 3D 的输入门槛低，但更依赖预训练模型和优化时间。本次 B/C 只完成了官方入口的 1 step 烟测，所以最终展示里仍然借助 proxy mesh 完成融合，这也是任务一最主要的不足。背景部分的 Mip-NeRF360 counter 训练效果相对稳定，说明当输入相机位姿和图像质量充分时，3DGS 能比较快得到可用的场景表示。

任务二中，ACT-A 和 ACT-ABC 的对比体现了跨环境数据的作用。state-only 结果中，A+B+C 混合训练在 D 环境上的 Action L1 更低；视觉版结果中，ACT-ABC 的 mean L1 没有直接变好，但 median L1 和 L1<0.10 的比例更好，说明小规模视觉训练下结果会更不稳定，但多环境数据仍然可能改善一部分样本的泛化表现。由于本实验只使用每个 split 的 4 个 episode，也没有接入 CALVIN simulator rollout，因此结论更适合作为离线动作误差分析，不能直接等同于真实任务成功率。

整体来看，本次实验完成了从真实拍摄物体、AIGC 物体生成、开源背景重建，到统一 Gaussian 表示融合的完整流程，也完成了 ACT 在不同训练域和未见环境上的离线对比。后续如果继续改进，我会优先延长 SDS/Zero123 的训练步数，扩大 CALVIN 数据规模，并进一步做真实环境 rollout，这样可以让生成质量和策略泛化结论都更充分。

### 参考文献

- [1] Jonathan T. Barron, Ben Mildenhall, Dor Verbin, Pratul P. Srinivasan, and Peter Hedman. Mip-nerf 360: Unbounded anti-aliased neural radiance fields. In *CVPR*, 2022.
- [2] Hugging Face. Lerobot. <https://github.com/huggingface/lerobot>, 2024.
- [3] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. *Robotics: Science and Systems*, 2023.